InsuLog

Guide Complet — Dataset & Modèle ML

Recommandation de doses d'insuline pour le diabète de type 1

Cours TECH60711 · HEC Montréal · 2026

Ce document explique, de A à Z, comment fonctionne le dataset synthétique InsuLog : sa structure, ses règles, ses variables X et Y, et son usage en Machine Learning.

1. Vue d'ensemble du projet

1.1 Qu'est-ce que InsuLog ?

InsuLog est une application mobile destinée aux personnes atteintes du **diabète de type 1**. Son rôle est de recommander une dose d'insuline à injecter avant un repas ou en cas de glycémie trop haute, en tenant compte de plusieurs facteurs personnels.

Contrairement aux pompes à insuline automatiques (boucle fermée), InsuLog fonctionne en **boucle ouverte** : l'algorithme propose une dose, mais c'est **toujours l'utilisateur qui valide et injecte manuellement**. Il garde le contrôle.

1.2 Pourquoi un modèle de Machine Learning ?

La dose optimale d'insuline varie énormément d'une personne à l'autre, et **même d'un moment à l'autre** pour la même personne. Un médecin peut calculer une dose de départ (formule ISF/ICR), mais l'affiner prend des semaines ou des mois.

Le ML permet à InsuLog de **apprendre des habitudes de chaque utilisateur** : si ses glycémies post-repas sont systématiquement trop hautes, le modèle détecte ce pattern et suggère d'ajuster les paramètres de dosage automatiquement.

Avantages concrets du ML dans InsuLog :

- Personnalisation : la dose s'adapte à votre corps, pas à une formule générique
- Apprentissage continu : plus vous l'utilisez, plus les recommandations s'améliorent
- Prise en compte de facteurs complexes : exercice, type de repas, heure, cycle hormonal
- Détection de patterns invisibles à l'oeil nu : phénomène de l'aube, hypoglycémies récurrentes

1.3 Chiffres clés du dataset

Paramètre	Valeur	Explication
Nombre d'entrées	50 000	Chaque ligne = 1 injection simulée
Nombre de patients	100	50 hommes / 50 femmes
Entrées par patient	500	≈ 500 injections sur 1 an
Nombre de colonnes	63	Variables X + Variables Y + métadonnées
Fichier train	35 000 lignes	70% des patients → entraînement du modèle

Fichier validation	7 500 lignes	15% des patients → ajustement du modèle
Fichier test	7 500 lignes	15% des patients → évaluation finale
Valeurs manquantes	0	Dataset propre, prêt à l'emploi

2. Comprendre l'apprentissage automatique

2.1 Le principe en une phrase

> *"Montrer au modèle des milliers d'exemples (X → Y), pour qu'il apprenne à prédire Y à partir de X sur de nouveaux cas jamais vus."*

Dans notre cas : on montre au modèle 50 000 injections passées avec leurs résultats. Il apprend à dire : *"si une personne de ce profil, à cette heure, avec cette glycémie et ces glucides, donne cette dose... voilà ce qui se passera."*

2.2 Les 3 types de tâches ML dans InsuLog

Type	Question posée	Réponse du modèle	Variable cible
Régression	Quelle dose exacte faut-il injecter ?	Un nombre en UI	**label_dose_optimal_ui**
Classification 5 cl.	La dose donnée était-elle bonne ?	1 classe parmi 5	**label_quality**
Classification binaire	La dose était-elle acceptable ?	Oui (1) ou Non (0)	**label_binary**

Pour InsuLog, la tâche principale recommandée est la **régression** (prédire une dose précise). La classification peut servir en complément pour expliquer à l'utilisateur si sa dernière injection était bien calibrée.

2.3 Le cycle d'entraînement

Étape	Description	Fichier utilisé
1. Entraînement	Le modèle apprend les relations X → Y sur les données d'entraînement	insulog_train.csv
2. Validation	On teste le modèle sur des patients non vus pour ajuster les hyperparamètres	insulog_val.csv
3. Évaluation finale	On mesure la performance réelle sur des patients totalement inconnus du modèle	insulog_test.csv
4. Déploiement	Le modèle est intégré dans l'app InsuLog pour recommander en temps réel	Données réelles

⚠️ Pourquoi diviser par patient (et non par ligne) ?

Si on mélangeait au hasard les lignes de tous les patients, le modèle pourrait **mémoriser les habitudes d'un patient spécifique** plutôt que d'apprendre à généraliser. En divisant par patient, on s'assure que le modèle est capable de faire de bonnes recommandations pour quelqu'un qu'il n'a jamais vu.

3. Les variables d'entrée (X) — ce que le modèle observe

Les variables X (aussi appelées **features** ou **variables prédictives**) sont les informations que le modèle reçoit pour faire sa recommandation. On les divise en 5 grandes familles.

3.1 Profil patient (données statiques)

Ces données ne changent pas d'une injection à l'autre. Elles définissent le profil physiologique de base du patient.

Colonne	Type	Description	Exemple
sex_enc	Binaire (0/1)	Sexe biologique (0=Femme, 1=Homme)	1
age	Entier	Âge en années	34
weight_kg	Décimal	Poids en kilogrammes	72.4
bmi	Décimal	Indice de masse corporelle (kg/m²)	24.1
act_enc	0/1/2	Niveau d'activité physique habituel	1 = modéré
diabetes_duration_years	Entier	Années depuis le diagnostic DT1	8
hba1c_pct	Décimal	HbA1c (contrôle glycémique moyen, %)	7.8
insulin_enc	0/1/2	Type d'insuline (Fiasp/Humalog/Novorapid)	1 = Humalog

3.2 Paramètres de dosage (calibrés par l'endocrinologue)

Ces valeurs sont calculées à l'initialisation de l'app et peuvent être ajustées par le modèle au fil du temps.

Colonne	Formule de calcul	Rôle	Exemple
tdd_ui	Dose totale / jour	Base de tous les calculs de dosage	42.0 UI
isf_mmol_per_ui	100 ÷ TDD	1 UI baisse la glycémie de X mmol/L	2.38
icr_g_per_ui	450 ÷ TDD	1 UI couvre X grammes de glucides	10.7
target_bg_mmol	Défini avec le médecin	Glycémie cible à atteindre après injection	6.0

iob_duration_h	Selon type insuline	Durée d'action de l'insuline (3-4h)	4.0

3.3 Données glycémiques en temps réel

Ces variables sont mesurées au moment de l'injection. Avec un capteur CGM connecté, elles sont automatiques ; sans capteur, l'utilisateur saisit sa glycémie manuellement.

Colonne	Description	Importance
bg_pre_mmol	Glycémie actuelle en mmol/L (ex : 10.2)	⭐ **Très élevée**
bg_trend_mmol_per_min	Tendance : vitesse de montée/descente (ex : +0.07)	⭐ **Élevée**
bg_vs_target	Écart entre la glycémie actuelle et la cible (ex : +4.2)	⭐ **Élevée**
bg_acceleration	2ème dérivée de la glycémie (accélération de la tendance)	**Moyenne**
iob_ui	Insuline encore active dans le corps (Insulin On Board)	⭐ **Très élevée**

> **L'IOB — Insulin On Board : le facteur le plus sous-estimé**
>
> L'IOB représente l'insuline **encore active dans le corps** depuis la dernière injection. Ne pas en tenir compte est la principale cause de surdosage en chaîne (stack) : on injecte, on trouve que ça ne descend pas assez vite, on ré-injecte, et on provoque une hypoglycémie.
>
> Dans InsuLog, l'IOB est calculé avec une **courbe de décroissance linéaire** sur la durée d'action (3-4h selon l'insuline). La dose finale est toujours réduite du montant d'IOB restant.

3.4 Repas

Colonne	Description	Valeurs possibles
has_meal	Est-ce une injection prandiale (avant repas) ?	0 = Correction seule / 1 = Repas
carbs_g	Quantité de glucides estimée en grammes	0 à 180 g
meal_enc	Type de repas (affect absorption)	0=aucun, 1=IG bas, 2=standard, 3=protéines, 4=IG élevé, 5=gras

time_since_meal_start_min	Minutes depuis le début du repas	0 à 20 min

Pourquoi le type de repas change-t-il la dose ?

Un repas riche en glucides à IG élevé (pain blanc, jus) fait monter la glycémie **très vite** → il faut agir rapidement avec une dose pleine.

Un repas gras (pizza, burger) ralentit l'absorption des glucides → la glycémie monte **en retard (1-2h après)**. Une dose immédiate complète risque de provoquer une hypo avant que le repas soit absorbé. Le facteur `meal_enc` capture ce phénomène.

3.5 Exercice physique

Colonne	Description	Impact
exercise_intensity	Intensité de l'exercice (0=aucun, 1=léger, 2=modéré, 3=intense)	Augmente la sensibilité à l'insuline
exercise_duration_min	Durée de l'exercice en minutes	Prolonge l'effet sensibilisant
hours_since_exercise	Heures écoulées depuis la fin de l'exercice	L'effet dure jusqu'à 12h après

⚠️ **Hypoglycémie post-exercice retardée — un danger méconnu**

L'exercice intense peut provoquer une hypoglycémie **jusqu'à 12h après** l'effort — même si la glycémie semblait normale juste après. C'est dû au reconstitution des réserves de glycogène musculaire, qui consomme du glucose sanguin en continu.

InsuLog réduit automatiquement la dose recommandée si un exercice récent a été déclaré. La réduction va de **-7% (léger)** à **-30% (intense)**, selon l'intensité et le temps écoulé.

3.6 Facteurs physiologiques calculés

Ces colonnes sont dérivées des données précédentes. Elles représentent les **ajustements physiologiques appliqués à l'ISF** pour tenir compte du contexte.

Colonne	Valeur typique	Description clinique
isf_effective	0.6 à 9.0	ISF réel après ajustements (ISF de base × tous les facteurs)

factor_dawn	0.82 – 1.0	Phénomène de l'aube : résistance accrue 5h-9h (ISF réduit)
factor_exercise	1.0 – 1.52	Sensibilité accrue après exercice (ISF augmenté)
factor_menstrual	0.87 – 1.0	Phase lutéale chez la femme : résistance accrue j14-j28 (ISF réduit)
factor_meal_type	0.80 – 1.12	Vitesse d'absorption des glucides selon le type de repas
factor_stress	0.88 – 1.0	Stress aigu → résistance à l'insuline légère (ISF réduit)
dawn_phenomenon_active	0 ou 1	Indicateur binaire : sommes-nous en période de phénomène de l'aube ?
somogyi_risk	0 ou 1	Indicateur : risque de rebond hyperglycémique nocturne (0h-3h)
menstrual_phase_luteal	0 ou 1	Indicateur : femme en phase lutéale (résistance hormonale)

4. Les variables cibles (Y) — ce que le modèle doit apprendre

Les variables Y (aussi appelées **labels**, **cibles** ou **vérité terrain**) sont ce que le modèle cherche à prédire. C'est ce qu'on lui montre pendant l'entraînement comme *"bonne réponse"*.

4.1 La logique d'étiquetage

Comment savoir quelle était la **bonne dose ?** En observant ce qui s'est passé **4 heures après l'injection**. C'est la fenêtre standard recommandée par le CHU Sainte-Justine pour évaluer la qualité d'un bolus.

> **Règle d'or : la glycémie 4h après injection devrait être entre 4.0 et 8.0 mmol/L**
>
> Si la glycémie 4h après est dans cette zone → la dose était optimale.
> Si elle est au-dessus → la dose était trop faible (sous-dosage). Il aurait fallu injecter plus.
> Si elle est en dessous → la dose était trop forte (sur-dosage). Risque d'hypoglycémie.

4.2 Les 3 variables Y expliquées

Y1 — label_dose_optimal_ui (Régression)

La dose, **en unités d'insuline (UI)**, que le patient aurait dû injecter pour atteindre une glycémie idéale 4h après. C'est la variable principale pour entraîner un modèle de régression.

Comment elle est calculée : si la glycémie 4h après était hors cible, on calcule rétrospectivement l'ajustement nécessaire :

Situation	Glycémie 4h après	Formule du label
Dose parfaite ✅	4.0 – 8.0 mmol/L	label = dose_donnée (rien à changer)
Léger sous-dosage ⚠️	8.0 – 10.0 mmol/L	label = dose_donnée + (écart ÷ ISF) × 50%
Sous-dosage 🔴	> 10.0 mmol/L	label = dose_donnée + (écart ÷ ISF)
Léger sur-dosage ⚠️	3.0 – 4.0 mmol/L	label = dose_donnée − (écart ÷ ISF) × 50%
Sur-dosage / Hypo 🔴	< 3.0 mmol/L	label = dose_donnée − (écart ÷ ISF)

Exemple concret : la glycémie 4h après est 12.5 mmol/L, ISF = 2.5, dose donnée = 4.0 UI.
→ Écart = 12.5 − 7.0 = 5.5 mmol/L (cible centre = 7.0)
→ Correction = 5.5 ÷ 2.5 = 2.2 UI
→ Label = 4.0 + 2.2 = 6.2 UI (il aurait fallu injecter 6.2 UI)

Y2 — label_quality (Classification 5 classes)

Catégorisation de la qualité du dosage. Utile pour **expliquer en langage clair** à l'utilisateur si sa dernière dose était bien calibrée.

Valeur texte	Code numérique	Signification
adjust_down 🔴	0	Sur-dosage sévère → glycémie < 3.0 mmol/L
adjust_down_mild ⚠️	1	Sur-dosage léger → glycémie 3.0–4.0 mmol/L
optimal ✅	2	Dose parfaite → glycémie 4.0–8.0 mmol/L
adjust_up_mild ⚠️	3	Sous-dosage léger → glycémie 8.0–10.0 mmol/L
adjust_up 🔴	4	Sous-dosage sévère → glycémie > 10.0 mmol/L

Y3 — label_binary (Classification binaire)

La version la plus simple : la dose était-elle **acceptable ou non** ? **1 = optimal**, **0 = ajustement nécessaire**.

4.3 Distribution des labels dans le dataset

La distribution n'est pas parfaitement équilibrée (c'est réaliste : un patient bien traité a ~70% de doses optimales). Pour certains algorithmes ML, il faudra utiliser des techniques de **ré-équilibrage (SMOTE, class_weight)** sur les classes minoritaires.

Label	Nb d'entrées	% du total	Interprétation
optimal ✅	~35 000	70%	Dose bien calibrée
adjust_up_mild ⚠️	~7 000	14%	Légère tendance au sous-dosage
adjust_up 🔴	~2 300	5%	Sous-dosage significatif
adjust_down_mild ⚠️	~2 800	6%	Légère tendance au sur-dosage
adjust_down 🔴	~2 400	5%	Sur-dosage / risque hypoglycémie

5. Les phénomènes cliniques simulés

Pour que le dataset soit cliniquement réaliste et que le modèle apprenne les véritables défis du diabète de type 1, nous avons intégré 6 phénomènes physiologiques connus.

5.1 Le phénomène de l'aube (Dawn Phenomenon)

Paramètre	Valeur
Quand	5h00 – 9h00 du matin
Cause	Libération naturelle de cortisol et de glucagon au réveil → résistance à l'insuline
Effet simulé	ISF réduit de 0 à 18% (pic à 7h)
Impact sur la dose	Le corps a besoin de plus d'insuline pour le même résultat
Colonne dans le dataset	dawn_phenomenon_active, factor_dawn

5.2 Le rebond de Somogyi

Paramètre	Valeur
Quand	0h00 – 3h00 (nuit)
Cause	Hypoglycémie nocturne non détectée → libération d'hormones de contre-régulation → rebond hyperglycémique
Effet simulé	Résistance légère entre 0h et 3h
Colonne dans le dataset	somogyi_risk

5.3 L'exercice physique et la sensibilité accrue

Intensité	Réduction de dose immédiate	Durée de l'effet
Légère (marche, yoga)	−7 à −12%	Jusqu'à 8h après
Modérée (vélo, natation)	−20 à −28%	Jusqu'à 10h après
Intense (course, sport)	−35 à −50%	Jusqu'à 12h après

L'intensité et la durée de l'exercice augmentent toutes deux la sensibilité à l'insuline. Le **risque d'hypoglycémie retardée** peut survenir jusqu'à 12 heures après un effort intense.

5.4 Le cycle menstruel (femmes)

Phase	Jours du cycle	Effet sur l'insuline
Phase folliculaire	Jours 1 – 13	Sensibilité normale (facteur = 1.0)
Phase lutéale	Jours 14 – 28	Résistance accrue : ISF réduit de 6–13% (effet de la progestérone)

C'est une des raisons pour lesquelles les femmes diabétiques constatent souvent des variations cycliques de leur glycémie. InsuLog le détecte et l'intègre dans le calcul.

5.5 Le type de repas et l'index glycémique

Type de repas	Facteur d'absorption	Exemple concret
Index glycémique élevé	×1.12	Jus d'orange, pain blanc, riz blanc
Standard	×1.00	Repas équilibré classique
Riche en protéines	×0.93	Steak, oeufs, tofu
Index glycémique bas	×0.87	Légumineuses, avoine, légumes
Riche en graisses	×0.80	Pizza, burger, poutine

5.6 Le stress

Le stress aigu libère de l'adrénaline et du cortisol, deux hormones qui augmentent la résistance à l'insuline. Dans le dataset, 12% des entrées intègrent un épisode de stress simulé (réduction de l'ISF de 5–12%).

6. Les profils patients — la diversité du dataset

6.1 Comment les patients sont générés

Les 100 patients sont créés avec des paramètres aléatoires mais contraints dans des plages cliniquement réalistes. La diversité est intentionnelle : plus le dataset couvre de profils différents, plus le modèle sera capable de s'adapter à un nouvel utilisateur.

6.2 Paramètres des profils

Paramètre	Hommes (50)	Femmes (50)
Âge	18 – 70 ans	18 – 68 ans
Poids	62 – 108 kg	50 – 88 kg
Taille	167 – 193 cm	154 – 176 cm
TDD moyen	~45 UI/jour	~32 UI/jour
ISF moyen	~2.2 mmol/L/UI	~3.0 mmol/L/UI
HbA1c	6.5 – 11.0 %	6.5 – 11.0 %
Durée du diabète	1 – 35 ans	1 – 35 ans

6.3 Pourquoi les femmes ont un ISF plus élevé que les hommes ?

L'ISF est calculé comme **100 ÷ TDD**. Les femmes ont généralement un TDD plus faible (car leur poids est plus faible et leur sensibilité à l'insuline tend à être plus grande), ce qui donne un ISF plus élevé. Cela signifie qu'**une unité d'insuline** fait baisser la glycémie de **plus de mmol/L** chez une femme de 55 kg que chez un homme de 90 kg.

6.4 Distribution des niveaux d'activité

Niveau d'activité	Proportion	TDD factor	Description
Sédentaire	35%	×0.62	Bureau, peu d'exercice régulier
Modéré	40%	×0.52	1-3 fois/semaine d'activité physique
Actif	25%	×0.42	Sport régulier, travail physique

7. Guide pratique — Entraîner le modèle

7.1 Choix de l'algorithme ML recommandé

Algorithme	Type	Avantages pour InsuLog	Complexité
Random Forest	Régression/Classification	Robuste, gère bien les non-linéarités, facile à interpréter	⭐⭐
XGBoost / LightGBM	Régression/Classification	Très performant sur données tabulaires, gère les valeurs manquantes	⭐⭐⭐
Réseau de neurones LSTM	Régression (séries temporelles)	Capture les patterns temporels (glycémies successives)	⭐⭐⭐⭐
Régression linéaire	Régression	Baseline simple, interprétable, point de départ idéal	⭐

Recommandation pour le prototype HEC : commencer avec un **Random Forest (régression)**. Simple à implémenter, performant sur ce type de données, et facilement explicable lors de la présentation.

7.2 Les 36 features X à utiliser

Catégorie	Colonnes
Profil patient	sex_enc, age, weight_kg, bmi, act_enc, tdd_ui, isf_mmol_per_ui, icr_g_per_ui, target_bg_mmol, iob_duration_h, insulin_enc
Glycémie	bg_pre_mmol, bg_trend_mmol_per_min, bg_vs_target, bg_acceleration, iob_ui
Repas	has_meal, carbs_g, meal_enc, time_since_meal_start_min
Exercice	exercise_intensity, exercise_duration_min, hours_since_exercise
Facteurs physio.	dawn_phenomenon_active, somogyi_risk, menstrual_phase_luteal, has_stress, isf_effective, factor_exercise, factor_dawn, factor_menstrual, factor_meal_type
Contexte temporel	hour, time_enc, day_of_week, month

7.3 Code de démarrage Python

Exemple de code pour démarrer l'entraînement :

```
import pandas as pd
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_absolute_error, r2_score

# Charger les données
train = pd.read_csv('insulog_train.csv')
val   = pd.read_csv('insulog_val.csv')

# Définir X et Y
features = ['sex_enc','age','weight_kg','bmi','tdd_ui','isf_mmol_per_ui',
            'icr_g_per_ui','bg_pre_mmol','bg_trend_mmol_per_min',
            'has_meal','carbs_g','meal_enc','iob_ui',
            'exercise_intensity','hours_since_exercise','isf_effective',
            'factor_exercise','factor_dawn','hour']

X_train = train[features]
y_train = train['label_dose_optimal_ui']
X_val   = val[features]
y_val   = val['label_dose_optimal_ui']

# Entraîner
model = RandomForestRegressor(n_estimators=200, random_state=42)
model.fit(X_train, y_train)

# Évaluer
preds = model.predict(X_val)
print('MAE:', mean_absolute_error(y_val, preds))  # erreur en UI
print('R² :', r2_score(y_val, preds))
```

7.4 Métriques d'évaluation

Métrique	Type de tâche	Interprétation pour InsuLog	Valeur cible
MAE (Mean Absolute Error)	Régression	Erreur moyenne en UI — ex : MAE=0.5 → ±0.5 UI d'erreur en moyenne	< 1.0 UI
RMSE	Régression	Pénalise les grandes erreurs — important pour la sécurité	< 1.5 UI
R^2	Régression	Variance expliquée (0=nul, 1=parfait)	> 0.85
Accuracy	Classification	% de doses bien classifiées	> 75%
F1-Score (weighted)	Classification	Équilibre précision/rappel sur toutes les classes	> 0.70

Considération de sécurité critique :

Dans un contexte médical, les **erreurs asymétriques** sont importantes. Une dose de 0.5 UI trop basse est moins dangereuse qu'une dose de 0.5 UI trop haute (risque d'hypoglycémie). Il faudra considérer des métriques ou des fonctions de perte **asymétriques** dans le modèle final.

8. Glossaire

Terme	Définition
CGM	Continuous Glucose Monitor — capteur de glycémie en continu (ex : Dexcom, Freestyle Libre). Mesure la glycémie toutes les 5-15 min.
TDD	Total Daily Dose — dose totale d'insuline injectée par jour (basale + bolus). Base de tous les calculs.
ISF	Insulin Sensitivity Factor — facteur de sensibilité. Indique de combien de mmol/L une unité d'insuline fait baisser la glycémie.
ICR	Insulin-to-Carb Ratio — ratio insuline/glucides. Indique combien de grammes de glucides sont couverts par 1 unité d'insuline.
IOB	Insulin On Board — insuline encore active dans l'organisme depuis la dernière injection.
Bolus prandial	Dose d'insuline injectée avant un repas pour compenser la montée de glycémie due aux glucides.
Bolus de correction	Dose d'insuline supplémentaire pour ramener une glycémie trop haute vers la cible.
HbA1c	Hémoglobine glyquée — mesure le contrôle glycémique moyen sur les 2-3 derniers mois (%).
Hypoglycémie	Glycémie trop basse (< 4.0 mmol/L). Symptômes : tremblements, sueurs, confusion.
Hyperglycémie	Glycémie trop haute (> 10 mmol/L). Symptômes à long terme : fatigue, complications vasculaires.
Feature (X)	Variable d'entrée utilisée par le modèle ML pour faire sa prédiction.
Label (Y)	Variable cible que le modèle cherche à prédire. La 'bonne réponse' lors de l'entraînement.
Train / Val / Test	Divisions du dataset : train pour l'apprentissage, val pour l'ajustement, test pour l'évaluation finale.
Overfitting	Quand le modèle 'mémorise' les données d'entraînement au lieu d'apprendre à généraliser.
MAE	Mean Absolute Error — erreur moyenne absolue. Ex : MAE = 0.8 UI signifie que le modèle se trompe de 0.8 UI en moyenne.
Boucle ouverte	Modèle où le système propose mais l'humain décide et agit. Opposé à la boucle fermée (pompe automatique).
Phase lutéale	Deuxième moitié du cycle menstruel (j14-28). Associée à une résistance accrue à l'insuline.

SMOTE	Technique d'augmentation de données pour équilibrer les classes minoritaires dans un dataset déséquilibré.

— Fin du document —